

# Copula的统计估计

杨静平

北京大学数学科学学院金融数学系

2019年10月

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# Copula的统计推断

数据为 $n$ 维向量列 $\{\mathbf{Y}_t, t = 1, 2, \dots, T\}$ 。可以代表金融资产的收益，或者股票的板块指数等。记

$$\mathbf{Y}_t = (Y_{1t}, Y_{2t}, \dots, Y_{nt})'$$

的分布和密度分别为 $F(\mathbf{y})$ 和 $f(\mathbf{y})$ 。其中，

$$\mathbf{y} = (y_1, \dots, y_n),$$

边缘分布分别记为 $f_j(y_j), F_j(y_j)$ 。下面我们考虑边缘分布是连续的情况。考虑 $n$ 维的数据。

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# 精确最大似然估计方法

对于分布函数

$$F(x_1, \dots, x_n) = C(F_1(x_1), \dots, F_n(x_n)),$$

有密度函数

$$f(x_1, x_2, \dots, x_n) = c(F_1(x_1), \dots, F_n(x_n)) \prod_{j=1}^n f_j(x_j)$$

其中,

$$c(u_1, u_2, \dots, u_n) = \frac{\partial C(u_1, u_2, \dots, u_n)}{\partial u_1 \dots \partial u_n}$$

令  $\chi_t = (x_{1t}, x_{2t}, \dots, x_{nt})$ ,  $t = 1, \dots, T$  为样本点序列。则有似然函数

$$l(\theta) = \sum_{t=1}^T \ln c(F_1(x_{1t}), F_2(x_{2t}), \dots, F_n(x_{nt})) + \sum_{t=1}^T \sum_{j=1}^n \ln f_j(x_{jt})$$

其中,  $\theta$ 是所有边缘分布和copula的参数集。

需要给出所有的边缘分布的估计, 以及定义相应的copula函数。

希望考虑最大似然估计

$$\hat{\theta}_{MLE} = \max_{\theta \in \Theta} l(\theta).$$

在给定的条件下, 有

$$\sqrt{T}(\hat{\theta}_{MLE} - \theta_0) \rightarrow N(0, \mathfrak{F}^{-1}(\theta_0))$$

其中,  $\mathfrak{F}(\theta_0)$ 为Fisher's 信息矩阵,  $\theta_0$ 是真值。



例子：多维正态分布。假设 $R$ 是一个对称的正定的矩阵， 对角元素都为1，  $\Phi_R$ 是斜方差阵为 $R$ 的标准正态分布，

$$C(u_1, u_2, \dots, u_n) = \Phi_R(\Phi^{-1}(u_1), \Phi^{-1}(u_2), \dots, \Phi^{-1}(u_n))$$

可计算似然函数

$$l(\theta) = -\frac{T}{2} \ln(|R|) - \frac{1}{2} \sum_{t=1}^T \epsilon'_t (R^{-1} - I) \epsilon_t$$

其中，

$$\epsilon'_t = (\Phi^{-1}(u_{1t}), \Phi^{-1}(u_{2t}), \dots, \Phi^{-1}(u_{nt}))$$

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

## IFM 方法

利用最大似然估计计算量大。因此， 可以采用另外的方法：

第一步： 根据边缘的数据估计边缘分布的参数 $\theta_1$ ,

$$\hat{\theta}_1 = \text{ArgMax}_{\theta_1} \sum_{t=1}^T \sum_{j=1}^n \ln f_j(x_{jt}; \theta_1).$$

第二步： 根据得到的 $\hat{\theta}_1$ , 估计copula的参数 $\theta_2$ ,

$$\hat{\theta}_2 = \text{ArgMax}_{\theta_2} \sum_{t=1}^T \ln c(F_1(x_1), F_2(x_2), \dots, F_n(x_n); \theta_2, \hat{\theta}_1).$$

这种方法称为inference for the margins (IFM). IFM的估计量定义为向量

$$\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2)'.$$

考虑 $l$ 是整体的似然函数,  $l_j$ 是第 $j$ 个边缘的似然函数,  $l_C$ 是copula  $C$ 的似然函数。因此IFM的解满足

$$\left(\frac{\partial l_1}{\partial \theta_{11}}, \frac{\partial l_2}{\partial \theta_{12}}, \dots, \frac{\partial l_n}{\partial \theta_{1n}}, \frac{\partial l_C}{\partial \theta_2}\right)' = 0$$

而最大似然函数满足

$$\left(\frac{\partial l}{\partial \theta_{11}}, \frac{\partial l}{\partial \theta_{12}}, \dots, \frac{\partial l}{\partial \theta_{1n}}, \frac{\partial l}{\partial \theta_2}\right)' = 0.$$

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# CML 方法

将样本数据 $\{x_{1t}, x_{2t}, \dots, x_{nt}\}$ 转换为均匀变量数据 $\{u_{1t}, u_{2t}, \dots, u_{nt}\}$ , 然后估计copula参数。

第一步： 根据边缘的数据估计边缘分布的经验分布 $\hat{F}_i(x_{it})$ ,  $i = 1, \dots, n$ . 使用非参数方法。

第二步： 通过最大似然估计来估计copula的参数：

$$\hat{\theta}_2 = \text{ArGMax}_{\theta_2} \sum_{t=1}^T \text{Inc}(\hat{F}_1(x_{it}), \hat{F}_1(x_{1t}), \dots, \hat{F}_n(x_{nt}); \theta_2).$$

这种方法称为Canonical Maximum Likelihood方法 (CML)。

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# 非参数估计

令

$$X_t = (X_{1t}, X_{2t}, \dots, X_{nt}), \quad t = 1, \dots, T$$

为i.i.d. 序列, 分布为 $F$ , 以及连续的边缘分布 $F_j$ . 令 $\{x_1^{(t)}, \dots, x_n^{(t)}\}$ 为次序统计量,  $\{r_1^{(t)}, \dots, r_n^{(t)}\}$ 为样本的Rank统计量。



Deheuvels' empirical copula. 经验copula被定义在格子点上, 满足

$$\mathcal{L} = \{(\frac{t_1}{T}, \frac{t_2}{T}, \dots, \frac{t_n}{T}) : 1 \leq j \leq n, t_j = 0, 1, \dots, T\}$$

则经验copula采用如下的数据来估计:

$$\hat{C}(\frac{t_1}{T}, \frac{t_2}{T}, \dots, \frac{t_n}{T}) = \frac{1}{T} \sum_{t=1}^T \prod_{j=1}^n I(r_j^{(t)} \leq t_j).$$

经验copula频率，定义为

$$\begin{aligned} & \hat{c}\left(\frac{t_1}{T}, \frac{t_2}{T}, \dots, \frac{t_n}{T}\right) \\ &= \sum_{i_1=1}^2 \sum_{i_2=1}^2 \cdots \sum_{i_n=1}^2 (-1)^{\sum_{j=1}^n i_j} \times \hat{C}\left(\frac{t_1 - i_1 + 1}{T}, \frac{t_2 - i_2 + 1}{T}, \dots, \frac{t_n - i_n + 1}{T}\right) \end{aligned}$$

Bernstein copula: 定义为

$$\begin{aligned} & B_T(C)(u_1, u_2, \dots, u_n) \\ &= \sum_{t_1=1}^n \sum_{t_2=1}^n \cdots \sum_{t_n=1}^n B_{t_1, T}(u_1) B_{t_2, T}(u_2) \cdots B_{t_n, T}(u_n) \hat{C}\left(\frac{t_1}{T}, \frac{t_2}{T}, \dots, \frac{t_n}{T}\right). \end{aligned}$$

其中，

$$B_{i,n}(x) = \binom{n}{i} x^i (1-x)^{n-i}.$$

# Outline

## 1 Copula的统计估计与模拟

- Copula的统计推断
- 精确最大似然估计方法
- IFM 方法
- CML 方法
- 非参数估计
- Kernel copula

# Kernel copula

Kernel意味着一种函数形式，通常用于平滑目的。核函数 $k_{ij}$ 满足

$$\int_R k_{ij}(x)dx = 1, i = 1, 2, \dots, m; j = 1, 2, \dots, n.$$

以及

$$K_i(x; h) = \prod_{j=1}^n k_{ij}\left(\frac{x_j}{h_j}\right), i = 1, 2, \dots, m.$$

其中带宽 $h_j$ 是 $T$ 的正的函数，满足

$$|h| + \frac{1}{T|h|} \rightarrow 0, T \rightarrow \infty.$$

$Y_{jt}$  的密度函数 $f_j(y_{ij})$ 需要通过如下的方法来估计：

$$\hat{f}_j(y_{ij}) = \frac{1}{Th_j} \sum_{t=1}^T k_{ij}\left(\frac{y_{ij} - Y_{it}}{h_j}\right)$$

联合密度函数

$$\hat{f}(y_{i1}, \dots, y_{in}) = \frac{1}{T|h|} \sum_{t=1}^T \prod_{j=1}^n k_{ij}\left(\frac{y_{ij} - Y_{it}}{h_j}\right).$$

因此可以得到 $Y_{jt}$ 的边缘分布函数

$$\hat{F}_j(y_{ij}) = \int_{-\infty}^{y_{ij}} \hat{f}_j(x) dx$$

以及 $\mathbf{Y}_t$ 的分布函数

$$\hat{F}(y_i) = \int_{-\infty}^{y_{i1}} \cdots \int_{-\infty}^{y_{in}} \hat{f}(x) dx.$$

实际中, Gaussian 核函数是一种选择:

$$k_{ij}(x) = \psi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

可以通过

$$\hat{C}(u_i) = \hat{F}(\hat{\xi}_i)$$

得到copula 函数。其中，

$$\hat{\xi}_i = (\hat{\xi}_{i1}, \dots, \hat{\xi}_{in})'$$

$$\hat{\xi}_{ij} = \inf_{y \in R} \{y : \hat{F}_j(y) \geq u_{ij}\}.$$

如果使用Gaussian Kernel 函数

$$k_{ij}(x) = \phi(x) = \frac{1}{\sqrt{2\pi}} \exp(-x^2/2).$$

则可以得到

$$\hat{F}_j(y_{ij}) = \frac{1}{Th_j} \sum_{t=1}^T \Phi\left(\frac{y_{ij} - Y_{jt}}{h_j}\right)$$

以及

$$\hat{F}(y_{i1}, \dots, y_{in}) = \frac{1}{T|h|} \sum_{t=1}^T \prod_{j=1}^n \Phi\left(\frac{y_{ij} - Y_{jt}}{h_j}\right).$$